Apache Kafka погружение на 45 минут

Григорий Кошелев Контур

Григорий Кошелев

- 10+ лет опыта создания Messaging и Stream Processing систем
- 5+ лет опыта работы с Apache Kafka
- 10+ докладов и выступлений про Apache Kafka

Основной стек Java/JVM

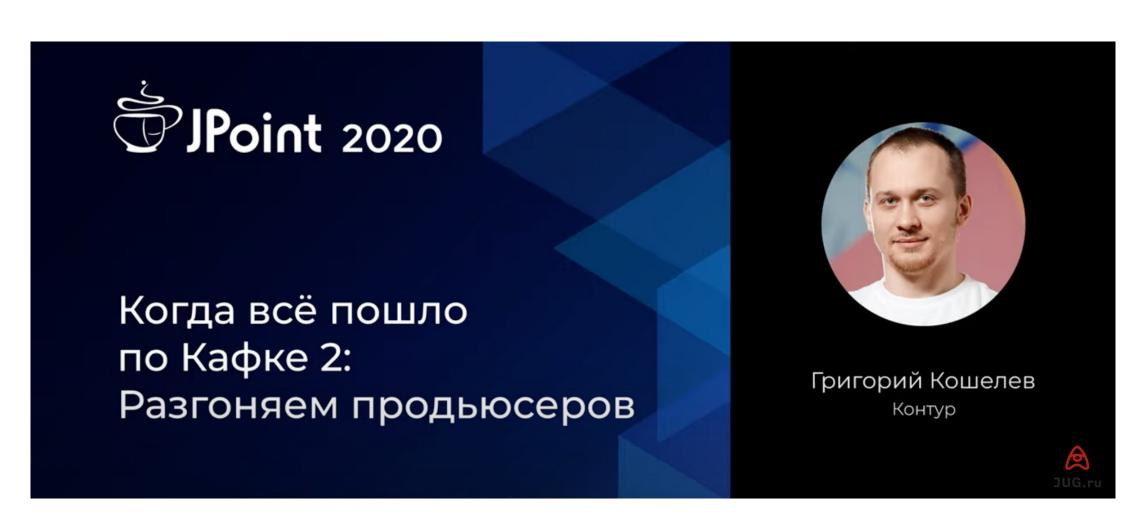




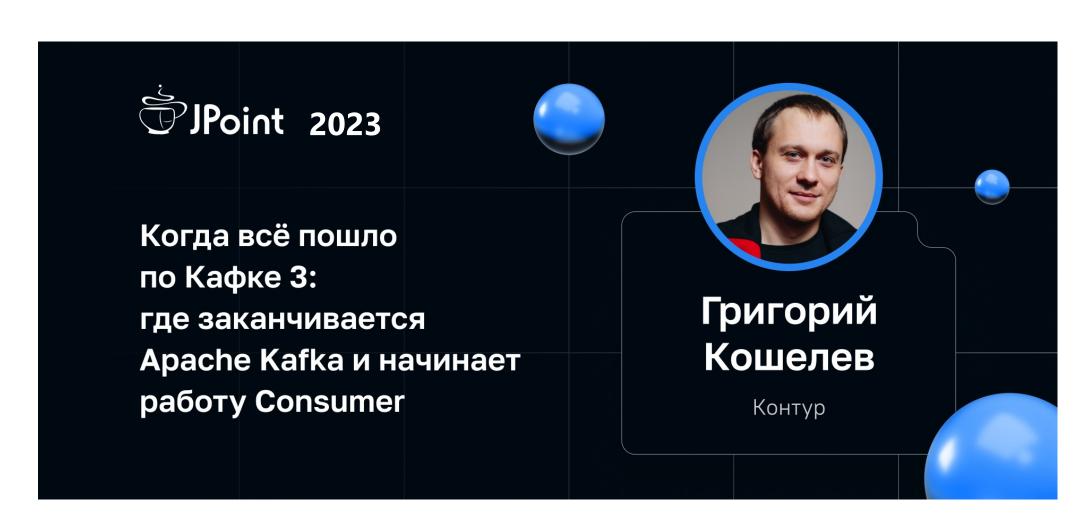
Трилогия «Когда всё пошло по Кафке»



Трилогия «Когда всё пошло по Кафке»



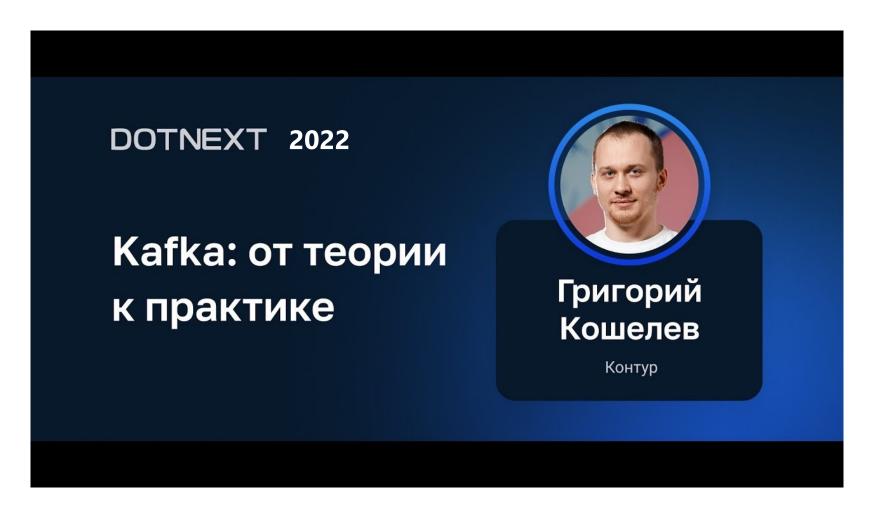
Трилогия «Когда всё пошло по Кафке»



Как готовить Кафку, чтобы не пригорало



Apache Kafka для .NET-разработчиков



Про что доклад

- 1. Введение в Apache Kafka
- 2. Kafka Producer
- 3. Kafka Consumer
- 4. Когда Apache Kafka 🤚
- 5. Подводные камни и ограничения

Чего не будет в докладе

- Kafka Streams
- KSQL
- Kafka Connect
- Mirror Maker
- Transactions

Около 20 кластеров Apache Kafka

Около 20 кластеров Apache Kafka

Около 20 кластеров Apache Kafka

По типу окружения

— Тестовое

Около 20 кластеров Apache Kafka

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование

Около 20 кластеров Apache Kafka

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг

Около 20 кластеров Apache Kafka

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг
- Продакшен

Около 20 кластеров Apache Kafka

По типу окружения

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг
- Продакшен

Около 20 кластеров Apache Kafka

По типу окружения

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг
- Продакшен

По назначению

— Телеметрия

Около 20 кластеров Apache Kafka

По типу окружения

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг
- Продакшен

- Телеметрия
- Интеграционная шина

Около 20 кластеров Apache Kafka

По типу окружения

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг
- Продакшен

- Телеметрия
- Интеграционная шина
- Шина данных

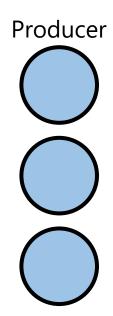
Около 20 кластеров Apache Kafka

По типу окружения

- Тестовое
 - * функ. тестирование
 - * нагрузочное тестирование
- Стейджинг
- Продакшен

- Телеметрия
- Интеграционная шина
- Шина данных
- **К**-архитектура

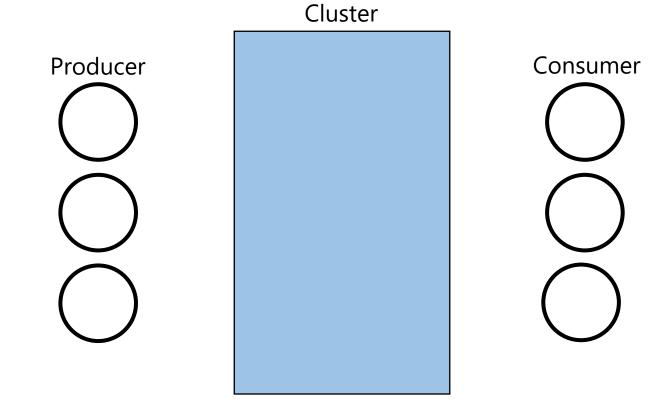
Kafka Producer



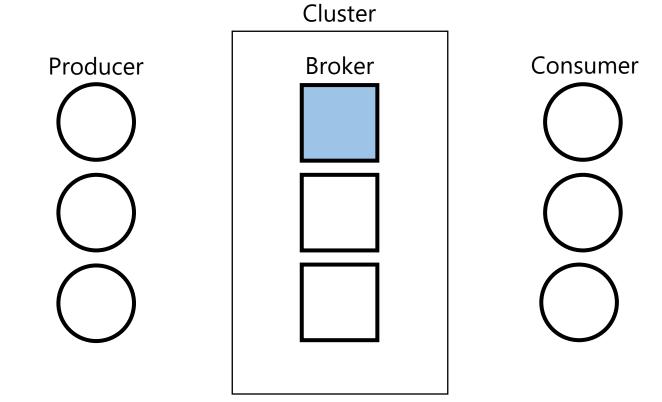
Kafka Consumer

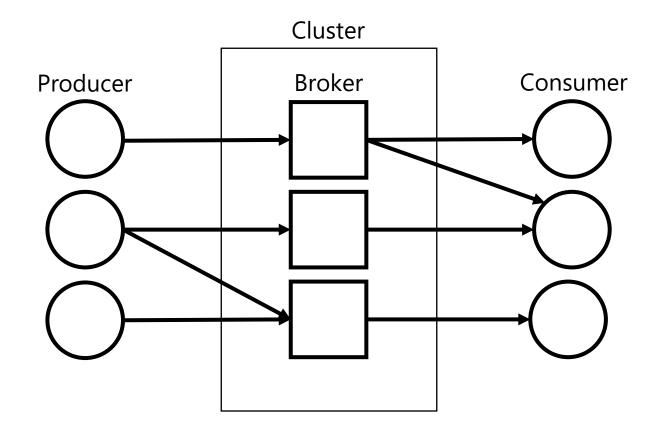


Kafka Cluster

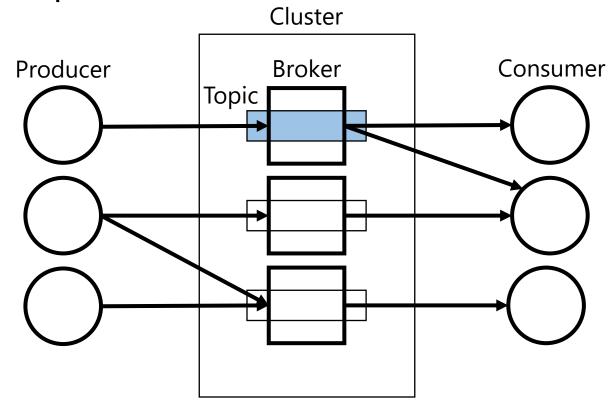


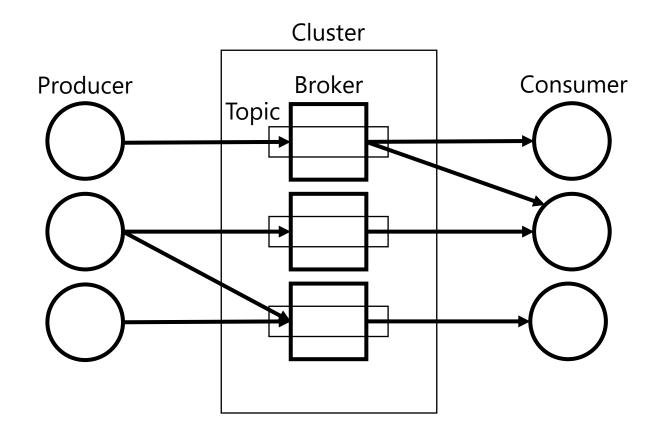
Kafka Broker



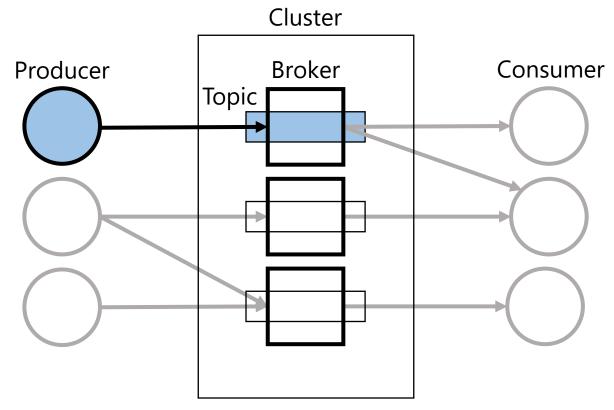


Kafka Topic

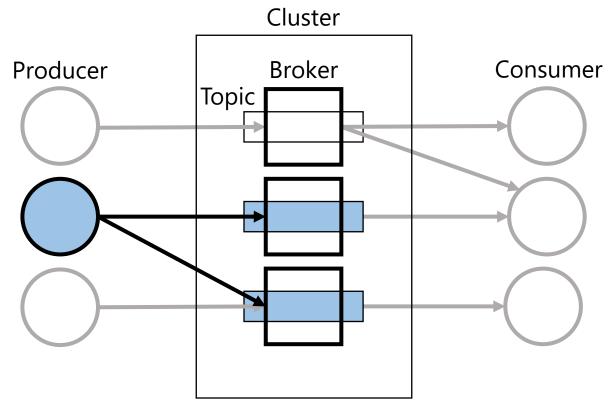




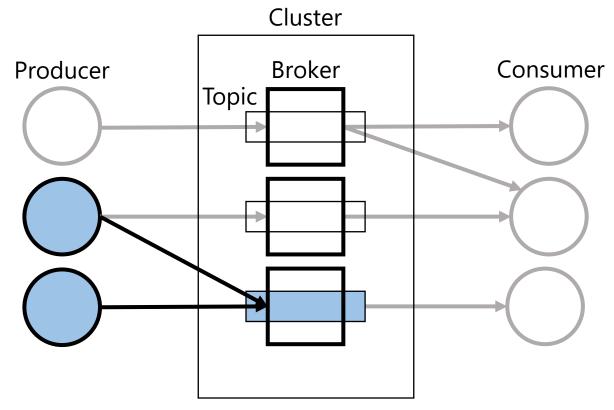
Отправка 1-to-1

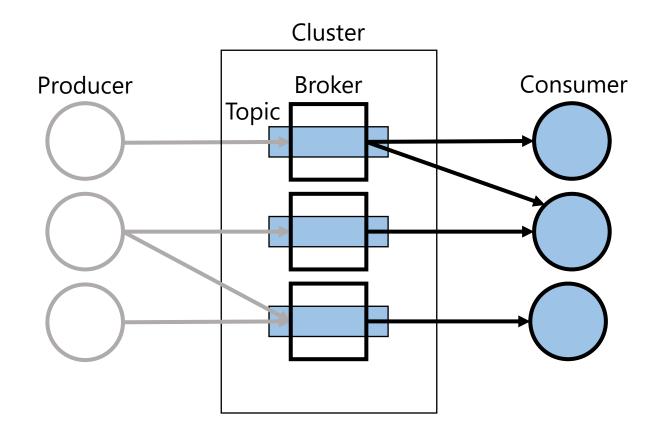


Отправка 1-to-N

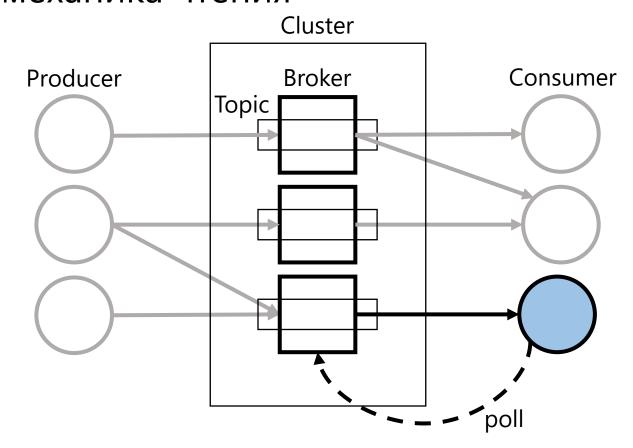


Отправка N-to-1





Poll-механика чтения

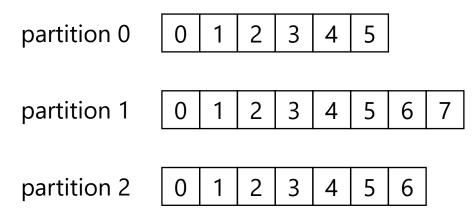


Архитектура Apache Kafka

- Topic
- Broker
- Producer
- Consumer

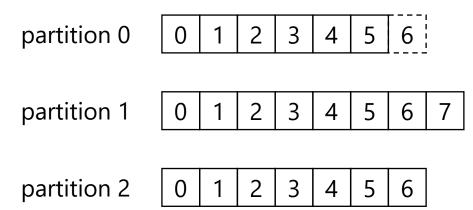
Архитектура Kafka Topic

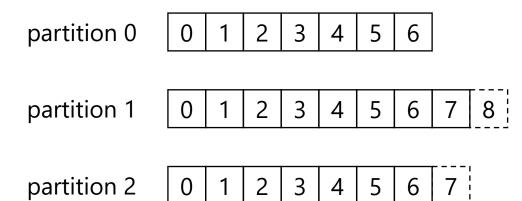
topic = {partition}

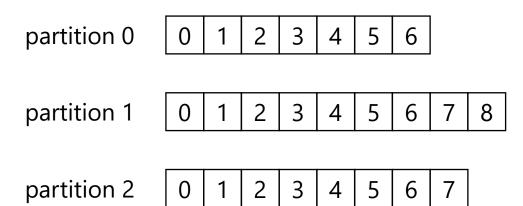


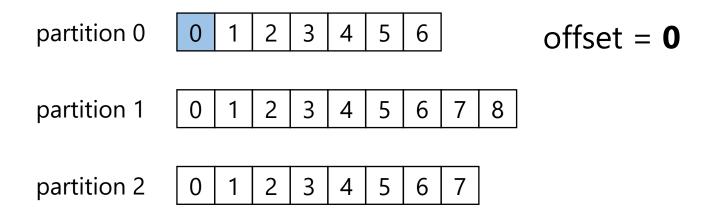
Архитектура Kafka Topic

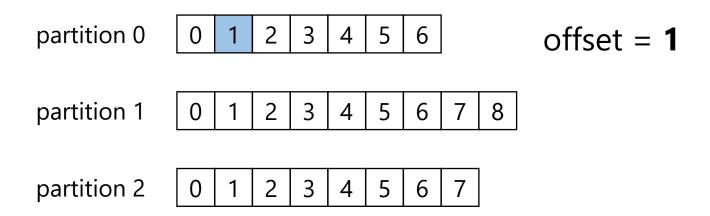
topic = {partition}

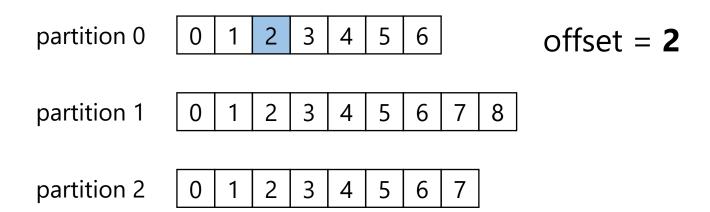


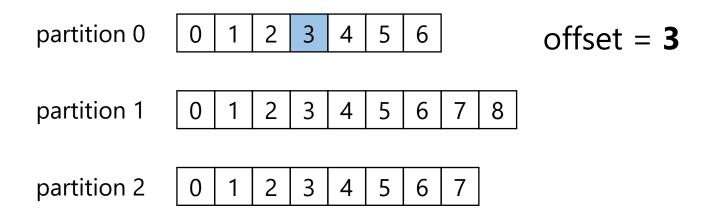






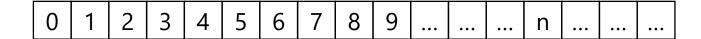




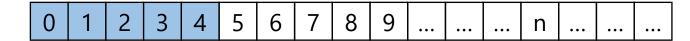


partition = {segment}

partition = {segment}

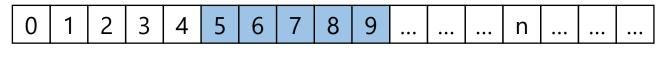


partition = {segment}



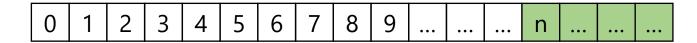
segment

partition = {segment}



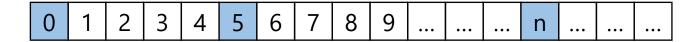
segment

partition = {segment}



segment

partition = {segment}



base offset

partition = {segment}

```
0 1 2 3 4 5 6 7 8 9 ... ... n ... n ... ...
```

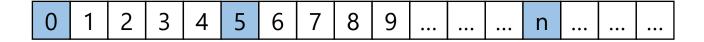
retention.bytes=-1 retention.ms=604800000

partition = {segment}

```
0 1 2 3 4 5 6 7 8 9 ... ... n ... ... ... ...
```

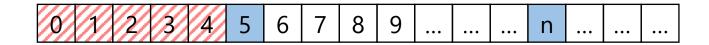
retention.bytes=-1
retention.ms=604800000

partition = {segment}



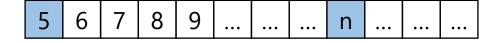
retention.bytes=-1
retention.ms=604800000

partition = {segment}



retention.bytes=-1 retention.ms=604800000

partition = {segment}



retention.bytes=-1 retention.ms=604800000

segment = (base_offset, data, index, timeindex)

00000000001234567890.log

0000000001234567890.index

segment = (**base_offset**, data, index, timeindex)

00000000001**234567890.**log

00000000001234567890.index

segment = (base_offset, **data**, index, timeindex)

0000000001234567890.log

0000000001234567890.index

segment = (base_offset, **data**, index, timeindex)

00000000001234567890.log

0000000001234567890.index

0000000001234567890.timeindex

log

segment = (base_offset, data, **index**, timeindex)

00000000001234567890.log

0000000001234567890.index

0000000001234567890.timeindex

log

Index record = (relative offset, position)

segment = (base_offset, data, index, timeindex)

00000000001234567890.log

0000000001234567890.index

0000000001234567890.timeindex

			log

Index record = (relative offset, position)

offset = 1234567890 relative offset = 0

size = 100 position = $\mathbf{0}$

segment = (base_offset, data, index, timeindex)

00000000001234567890.log

0000000001234567890.index

0000000001234567890.timeindex



Index record = (relative offset, position)

offset = 123456789**1** relative offset = **1**

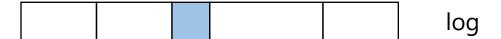
size = 100 position = **100**

segment = (base_offset, data, index, timeindex)

00000000001234567890.log

0000000001234567890.index

0000000001234567890.timeindex



Index record = (relative offset, position)

offset = 1234567892 relative offset = 2

size = 50 position = **200**

segment = (base_offset, data, **index**, timeindex)

00000000001234567890.log

0000000001234567890.index

0000000001234567890.timeindex



Index record = (relative offset, position)

offset = 1234567893 relative offset = 3

size = 150 position = **250**

segment = (base_offset, data, index, **timeindex**)

00000000001234567890.log

0000000001234567890.index

Выводы

- Топик разбит на партиции
- Партиции хранятся на диске
- Данные удаляются либо по времени, либо по размеру
- Сообщение можно быстро найти по его Offset

cluster = {broker}

broker 1	broker 2	broker 3

Controller – координирует работу кластера

broker 1	broker 2	broker 3

topic = {partition}

broker 1 broker 2 broker 3 partition 0 partition 1 partition 2 partition 3

replication factor = 3

broker 1

partition 0

partition 1

partition 2

partition 3

broker 2

partition 0

partition 1

partition 2

partition 3

broker 3

partition 0

partition 1

partition 2

partition 3

Добавление partition

broker 1

partition 0

partition 1

partition 2

partition 3

partition 4

broker 2

partition 0

partition 1

partition 2

partition 3

partition 4

broker 3

partition 0

partition 1

partition 2

partition 3

partition 4

broker 1 – leader для partition 0.

broker 1 broker 2 broker 3 partition 0 partition 0 partition 0 leader partition 1 partition 1 partition 1 partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

broker 2 – leader для partition 1

broker 1 broker 2 broker 3 partition 0 partition 0 partition 0 leader partition 1 partition 1 partition 1 partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

broker 3 – leader для partition 2

broker 1 broker 2 broker 3 partition 0 partition 0 partition 0 leader partition 1 partition 1 partition 1 partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

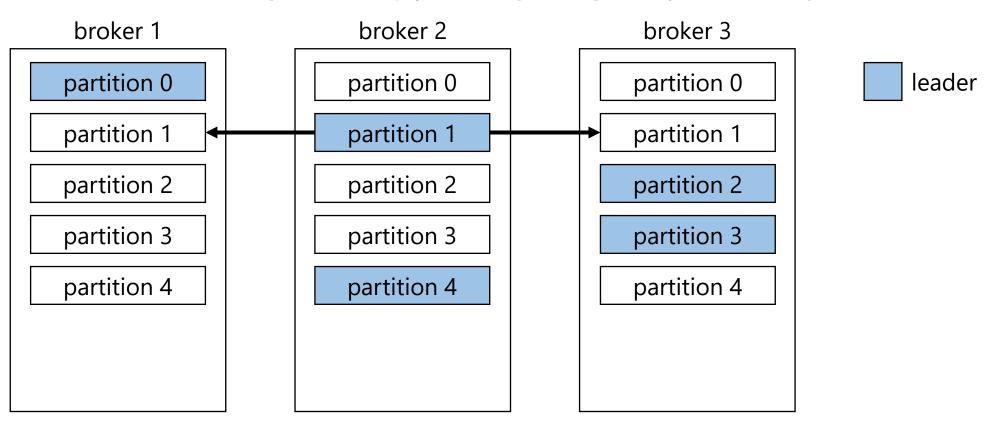
broker 3 – leader для partition 3

broker 1 broker 2 broker 3 partition 0 partition 0 partition 0 leader partition 1 partition 1 partition 1 partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

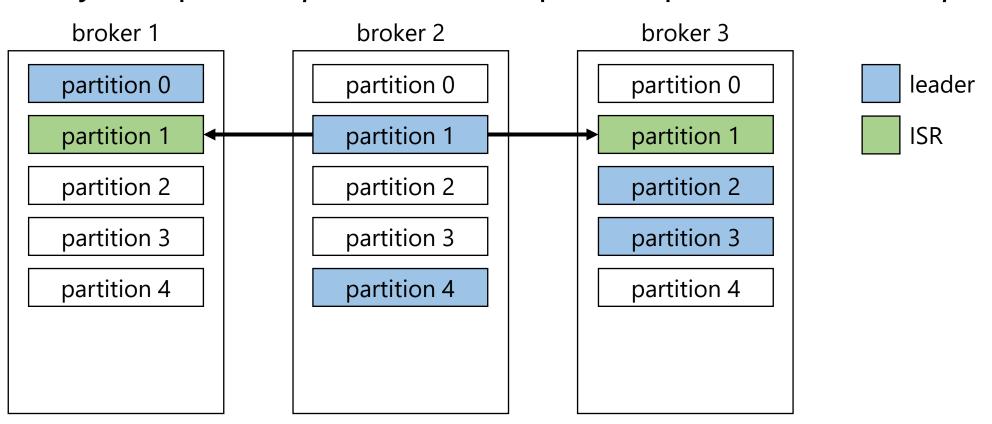
broker 2 – leader для partition 4

broker 1 broker 2 broker 3 partition 0 partition 0 partition 0 leader partition 1 partition 1 partition 1 partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

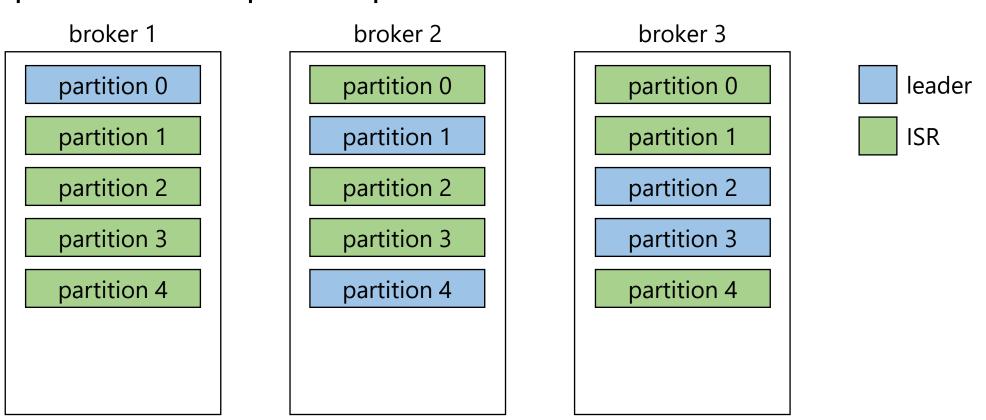
Репликация с лидера на другие брокеры (фолловеры)



ISR (in sync replica) – *реплика*, синхронизированная с *лидером*



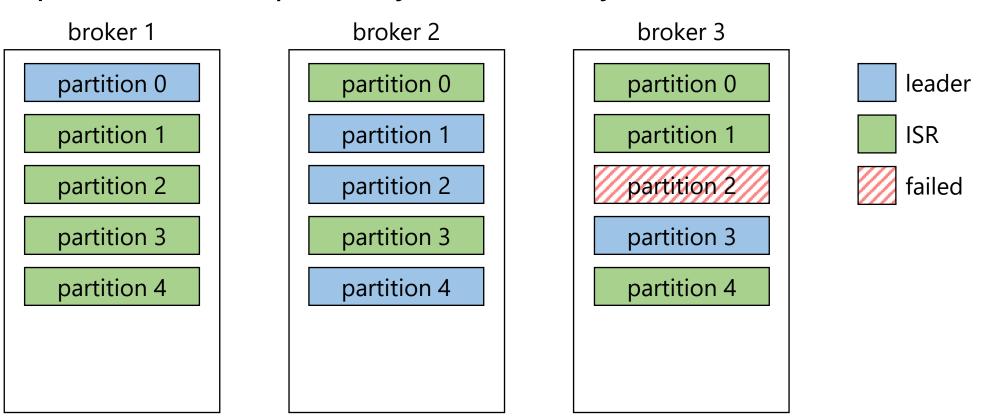
Все реплики синхронизированы



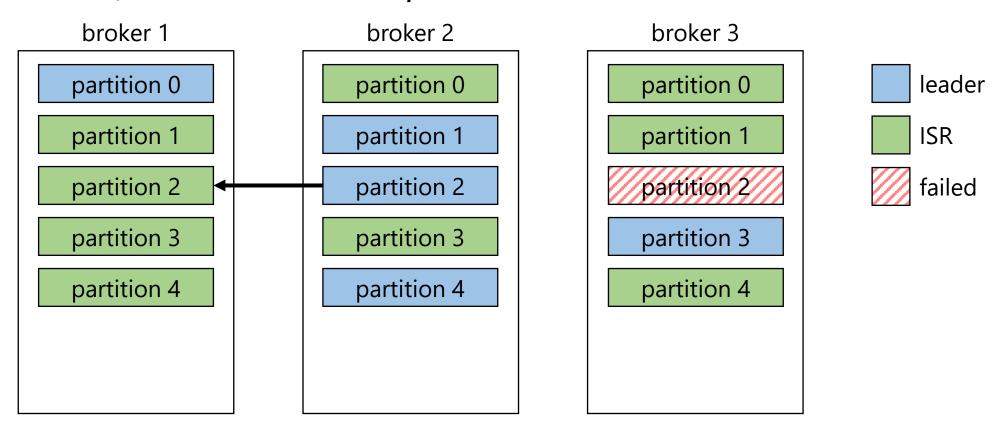
Недоступность лидера y partition 2

broker 1 broker 2 broker 3 partition 0 partition 0 partition 0 leader ISR partition 1 partition 1 partition 1 failed partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

Выбор нового лидера в случае недоступности

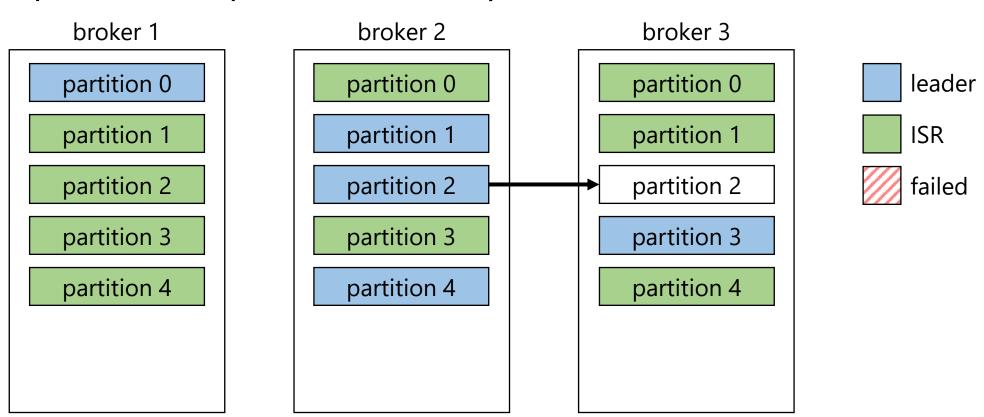


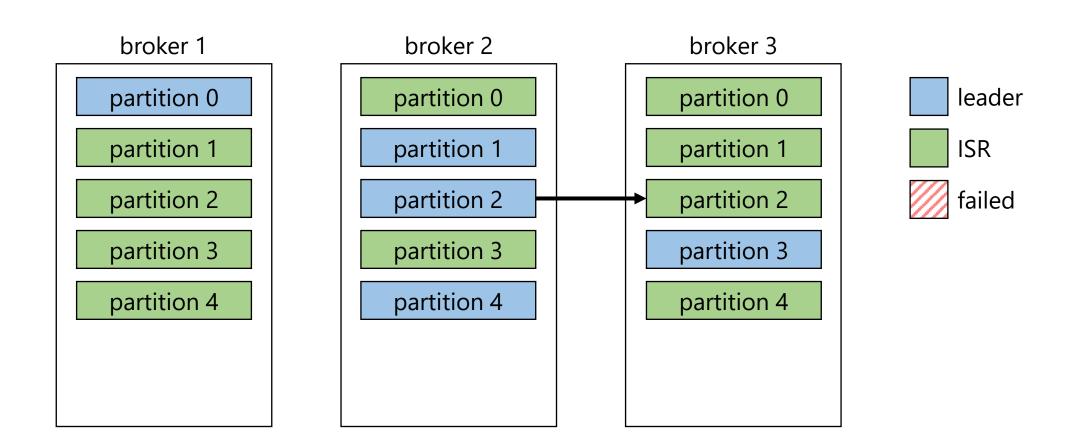
Репликация с нового лидера



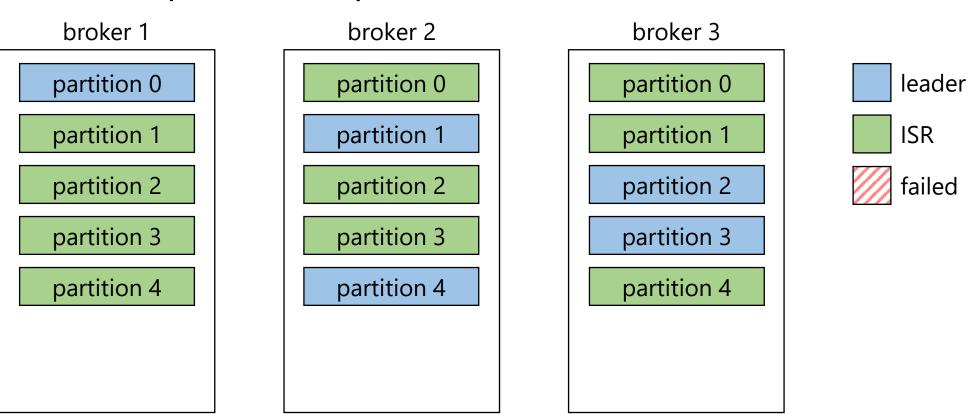
broker 1 broker 2 broker 3 leader partition 0 partition 0 partition 0 ISR partition 1 partition 1 partition 1 failed partition 2 partition 2 partition 2 partition 3 partition 3 partition 3 partition 4 partition 4 partition 4

Синхронизация реплики с лидером после восстановления





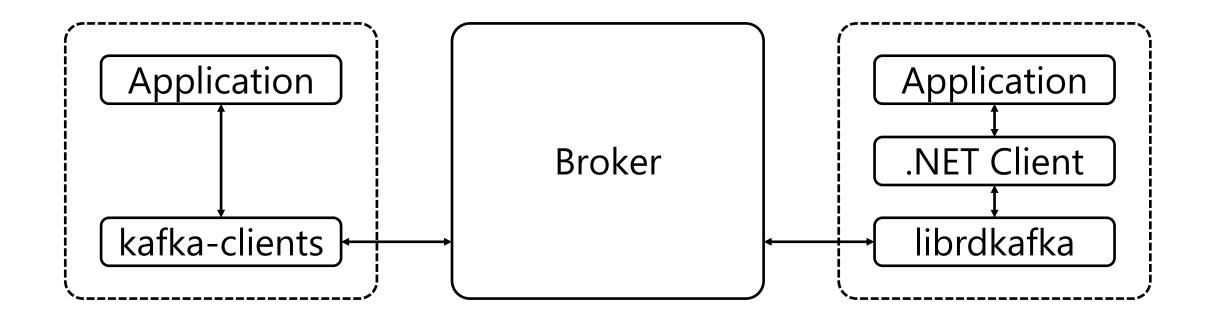
Перебалансировка лидеров



Выводы

- У каждой партиции свой Лидер
- Сообщения пишутся в Лидера
- Данные реплицируются между брокерами
- Автоматический фейловер лидерства

Kafka Client: Java vs все остальные



```
new KafkaProducer<TKey,TValue>(
          producerProperties,
          keySerializer,
          valueSerializer
)
```

```
# Producer properties
bootstrap.servers =
  host1:port1,host2:port2,...
```

```
# Producer properties

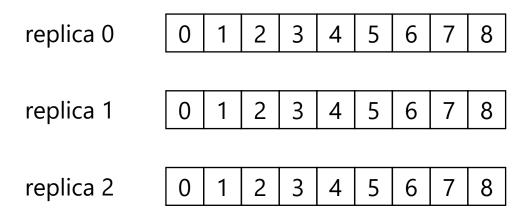
partitioner.class =
   null |
   o.a.k.clients.producer.RoundRobinPartitioner |
   o.a.k.clients.producer.UniformStickyPartitioner |
   ...
```

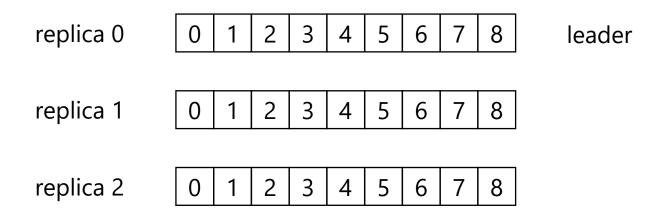
```
// ...
producer.send(
    record,
    (metadata, exception) → {/* callback */}
);
```

```
// ...
producer.send(
    record,
    (metadata, exception) → {/* callback */}
);
```

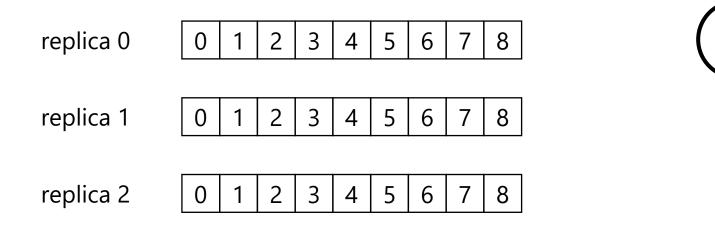
```
// ...
producer.send(
    record,
    (metadata, exception) → {/* callback */}
);
```

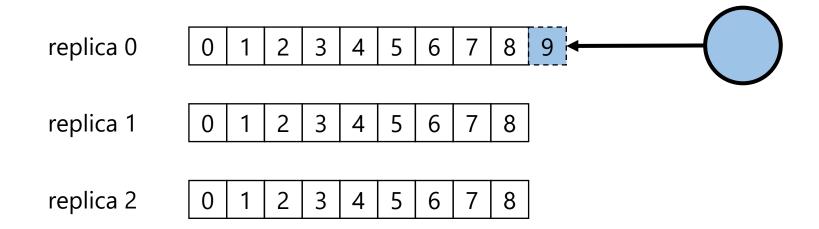
```
# Producer properties
acks = 0 | 1 | all
```



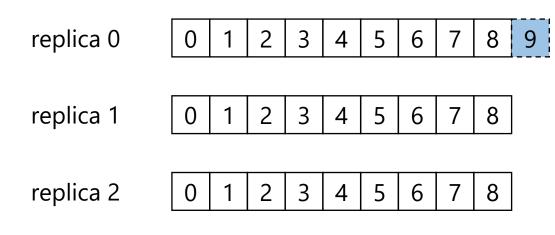


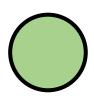
replica 0	0 1	2	3	4	5	6	7	8	leader
replica 1	0 1	2	3	4	5	6	7	8	ISR
replica 2	0 1	2	3	4	5	6	7	8	ISR





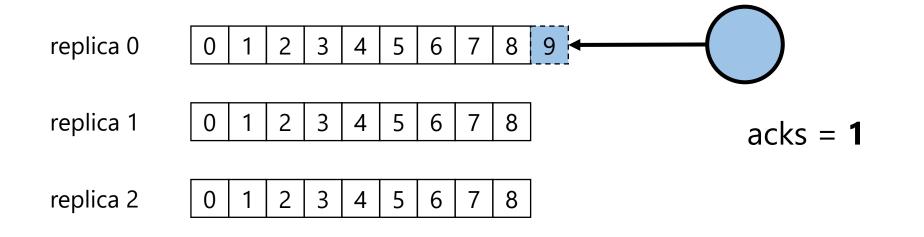




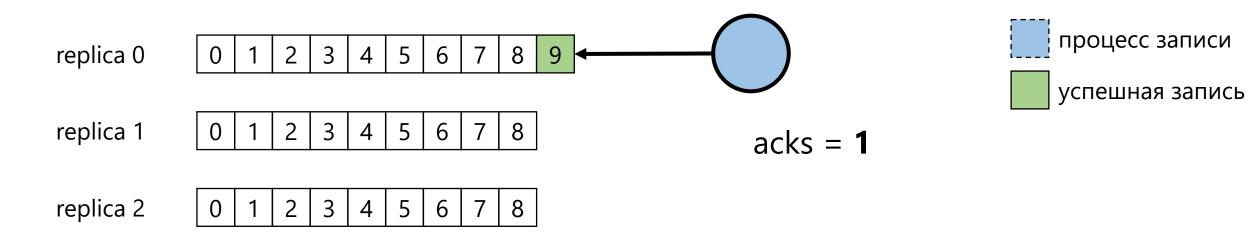


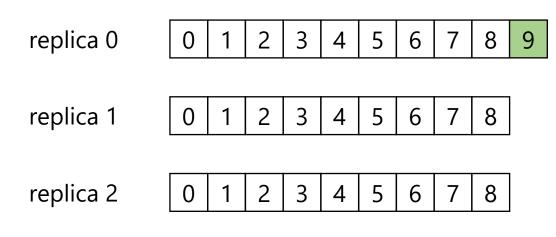


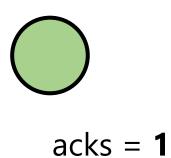
$$acks = 0$$

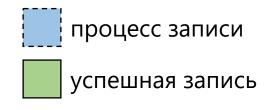


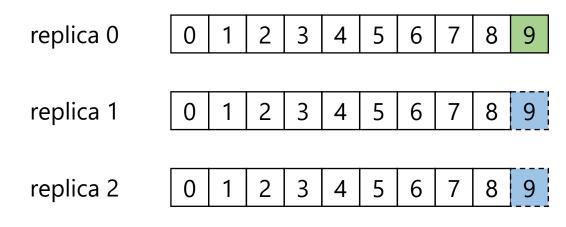


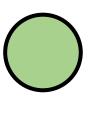




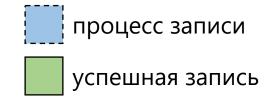


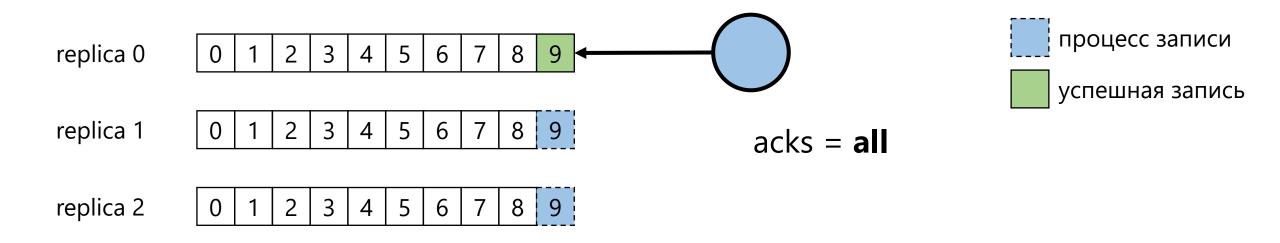


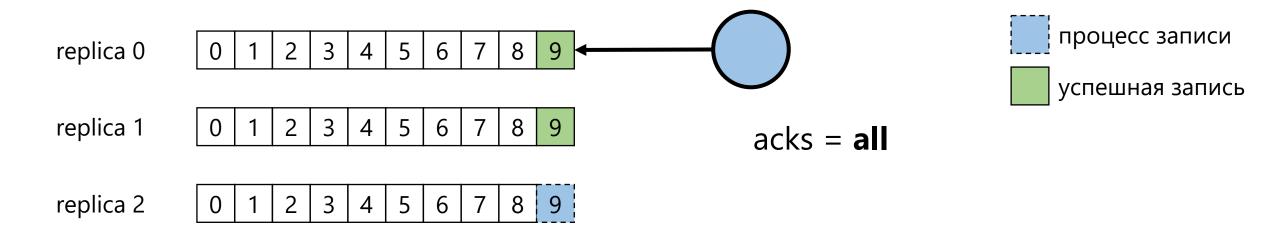


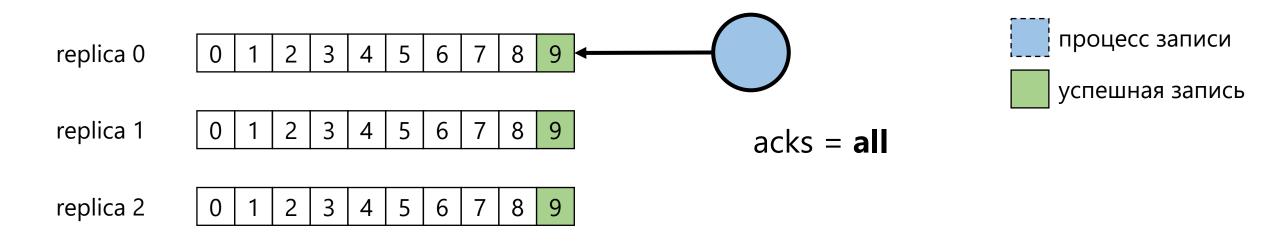


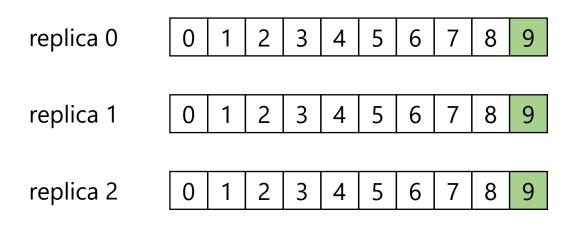


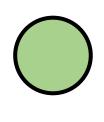




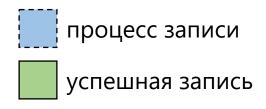


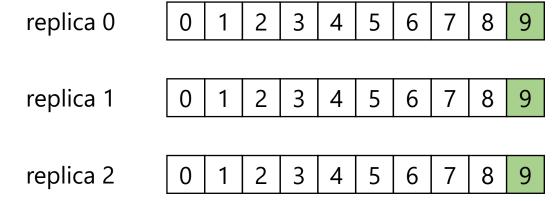


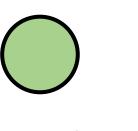


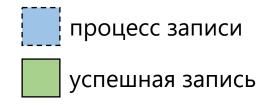


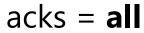
acks = **all**



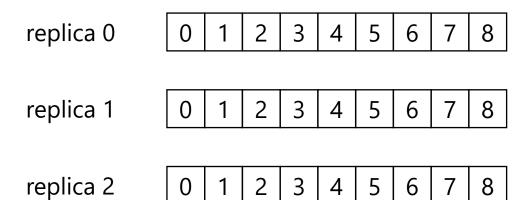




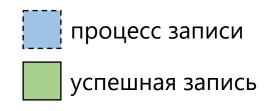


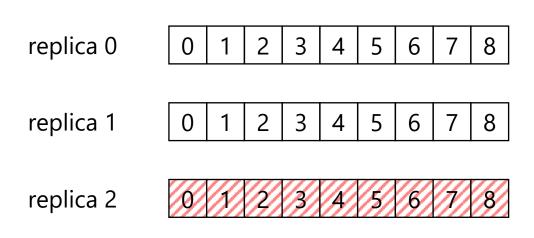


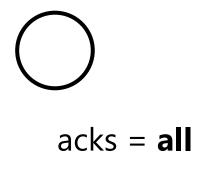




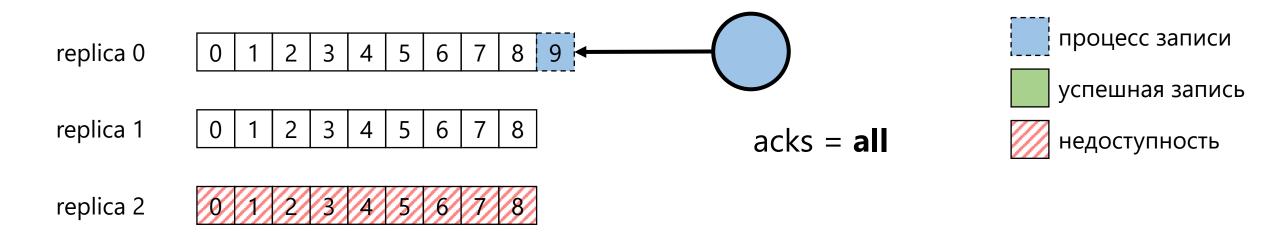


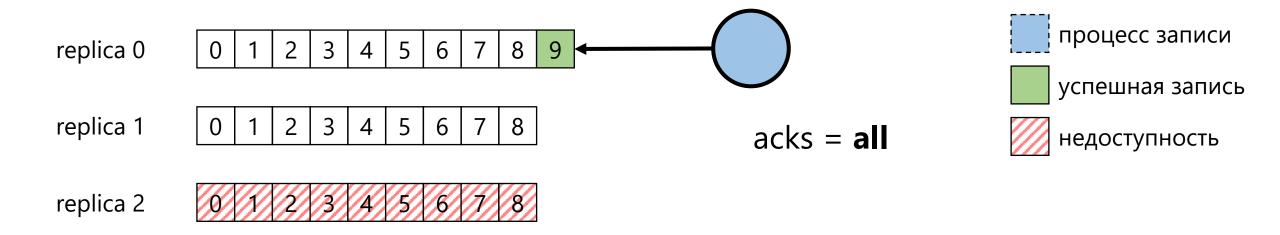


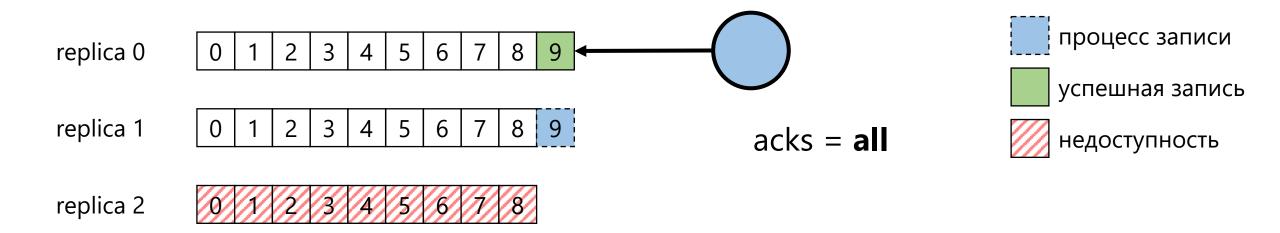


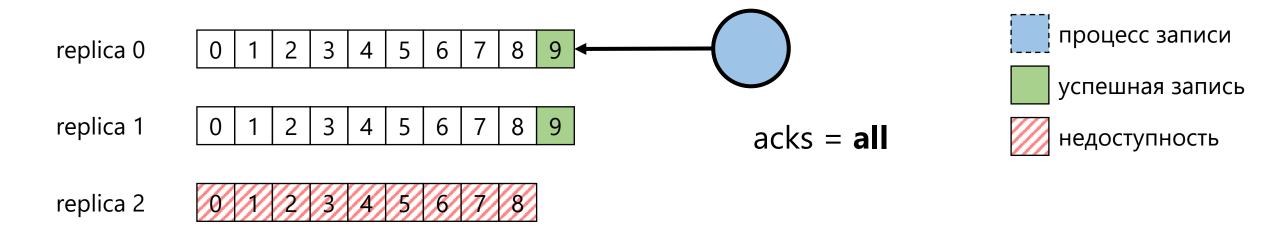




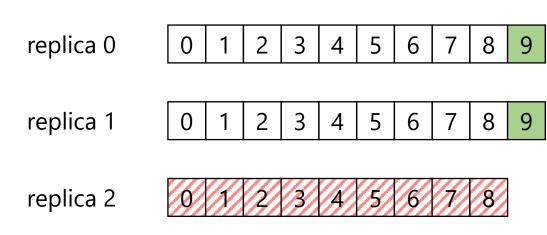


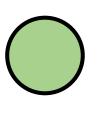




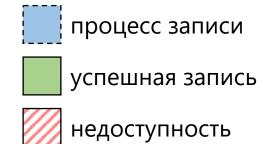


Topic config: min.insync.replicas = 2





acks = **all**



Производительность



Производительность

- Низкая задержка
- Высокая пропускная способность

Производительность

- Низкая задержка
- Высокая пропускная способность

Производительность

- Низкая задержка
- Высокая пропускная способность

msg

Производительность

- Низкая задержка
- Высокая пропускная способность

msg msg

Производительность

- Низкая задержка
- Высокая пропускная способность

msg msg msg

Производительность

- Низкая задержка
- Высокая пропускная способность

msg msg msg

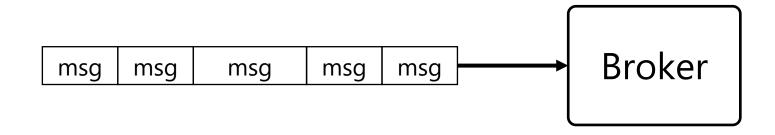
Производительность

- Низкая задержка
- Высокая пропускная способность

msg msg msg msg

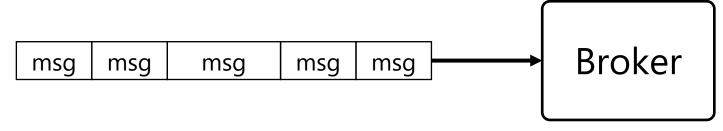
Производительность

- Низкая задержка
- Высокая пропускная способность



Производительность

- Низкая задержка
- Высокая пропускная способность



Производительность

- Низкая задержка
- Высокая пропускная способность

msg

Broker

Производительность

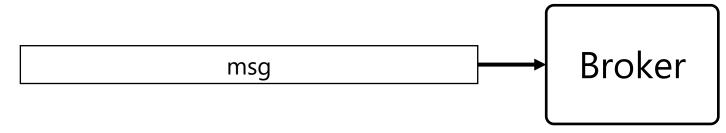
- Низкая задержка
- Высокая пропускная способность

msg

Broker

Производительность

- Низкая задержка
- Высокая пропускная способность



Производительность

- Низкая задержка
- Высокая пропускная способность

Broker

batch.size = 100000
linger.ms = 5

Производительность

- Низкая задержка
- Высокая пропускная способность

msg

batch.size = 100000
linger.ms = 5

Производительность

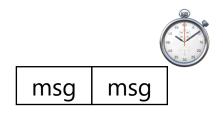
- Низкая задержка
- Высокая пропускная способность

msg msg

batch.size = 100000
linger.ms = 5

Производительность

- Низкая задержка
- Высокая пропускная способность

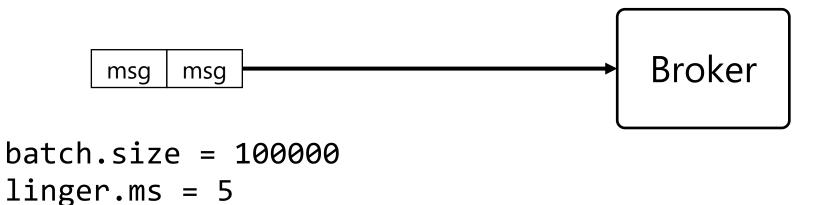


batch.size = 100000
linger.ms = 5

Broker

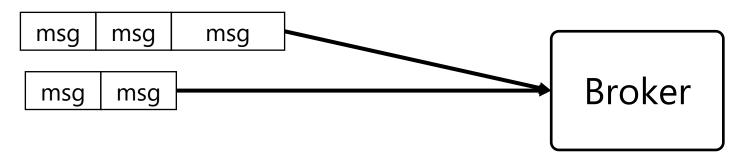
Производительность

- Низкая задержка
- Высокая пропускная способность



Производительность

- Низкая задержка
- Высокая пропускная способность



```
batch.size = 100000
linger.ms = 5
max.request.size = 1000000
```

Производительность

- Низкая задержка
- Высокая пропускная способность



```
# Producer properties
compression.type =
   none | gzip | snappy | lz4 | zstd
```

```
# Producer properties
compression.type =
    none | gzip | snappy | lz4 | zstd
```

Выводы

- Producer выбирает партицию для сообщения
- Producer определяет уровень гарантии доставки
- B Producer можно тюнить производительность

```
# Consumer properties
bootstrap.servers =
  host1:port1,host2:port2,...
```

```
// Подписаться на список топиков consumer.subscribe(topics);

// Подписаться на топики по шаблону имени consumer.subscribe(pattern);
```

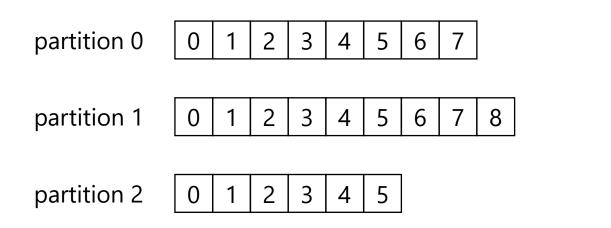
```
// Подписаться на список топиков consumer.subscribe(topics);
```

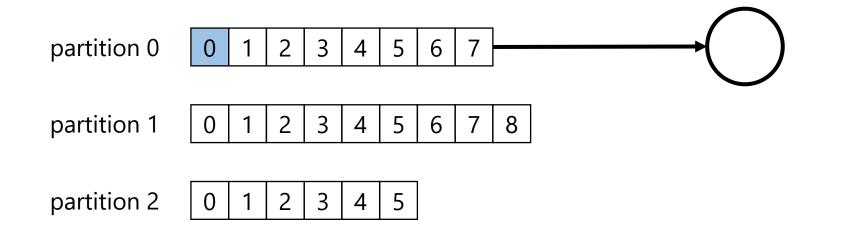
```
// Подписаться на топики по шаблону имени consumer.subscribe(pattern);
```

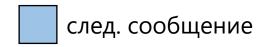


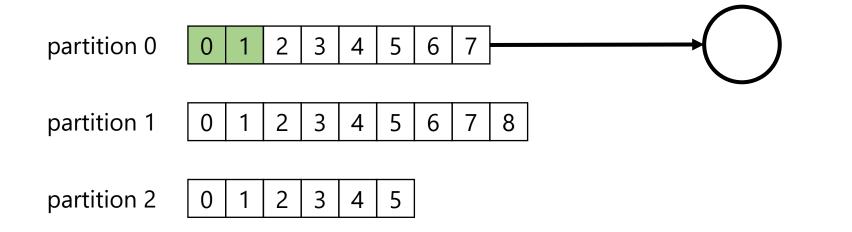
```
ConsumerRecords<UUID, Event> records =
    consumer.poll(Duration.ofSeconds(5));
```

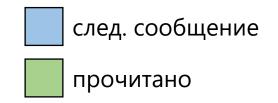
```
ConsumerRecords<UUID, Event> records =
    consumer.poll(Duration.ofSeconds(5));
```



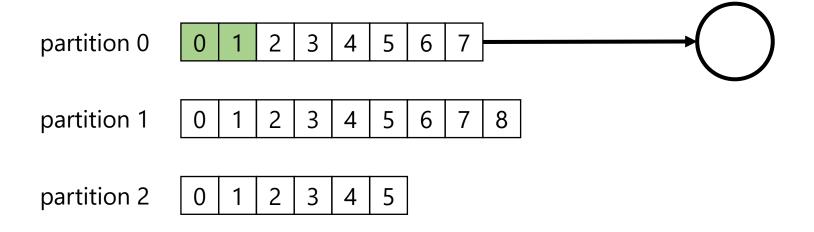


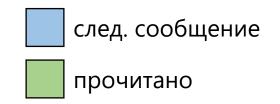


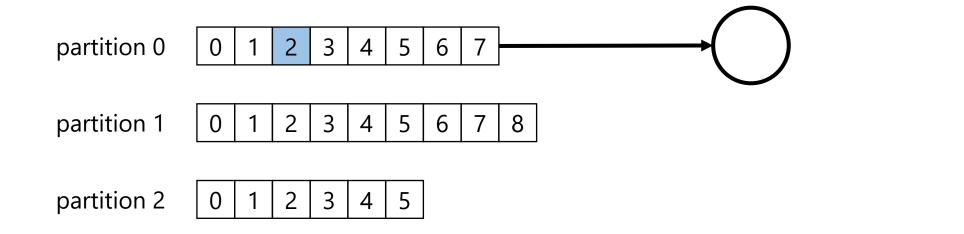


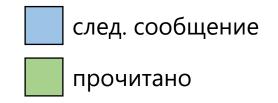


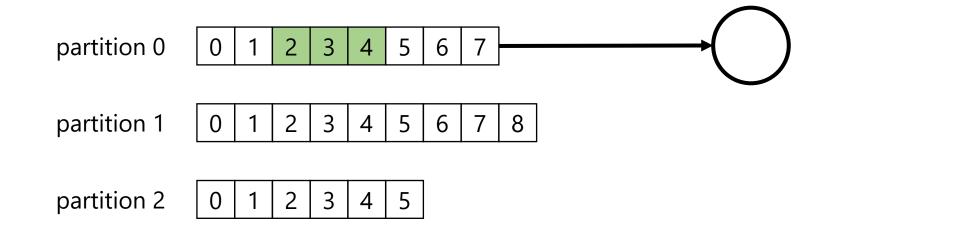
max.poll.records = 500

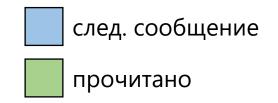


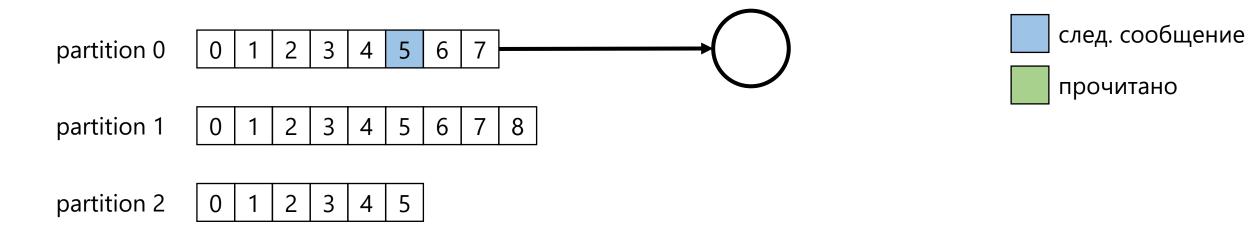


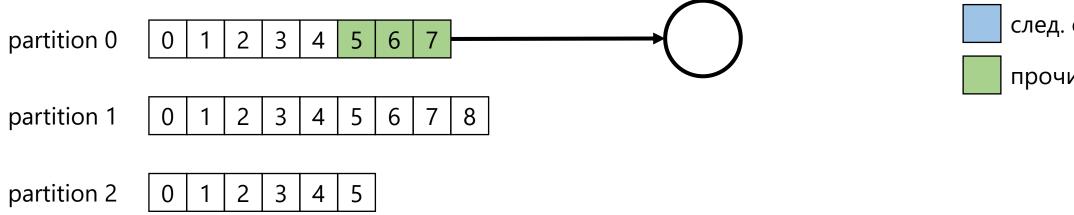


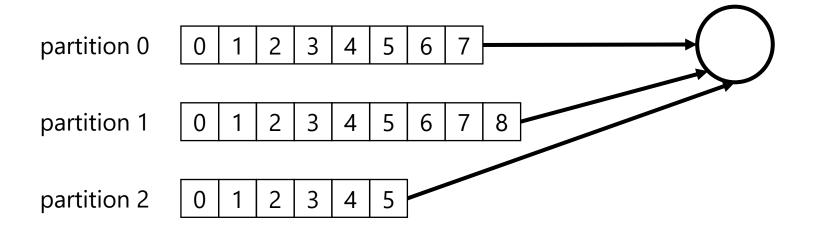


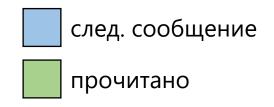


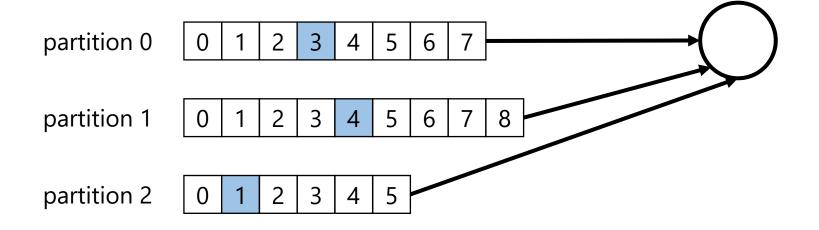


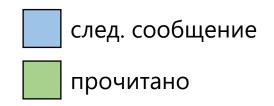


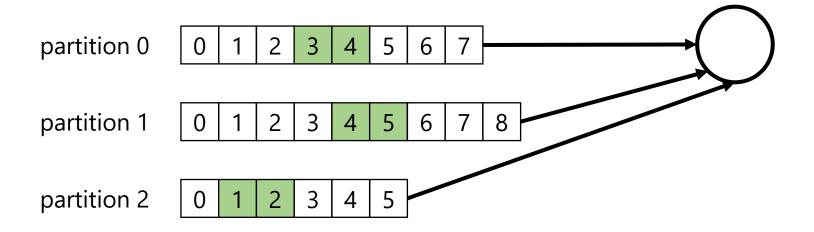


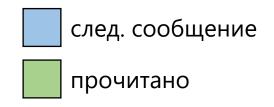


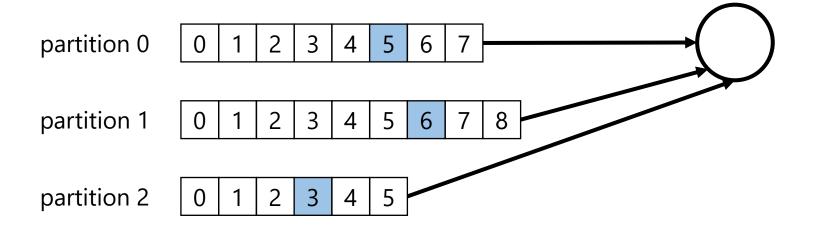


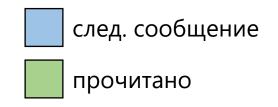


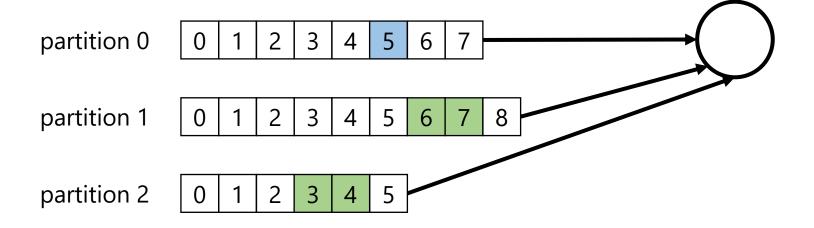


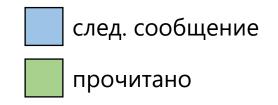


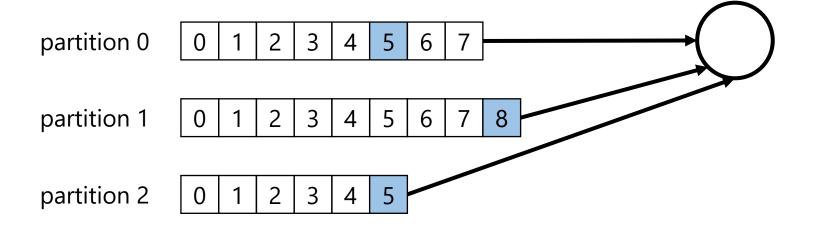


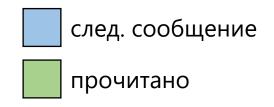


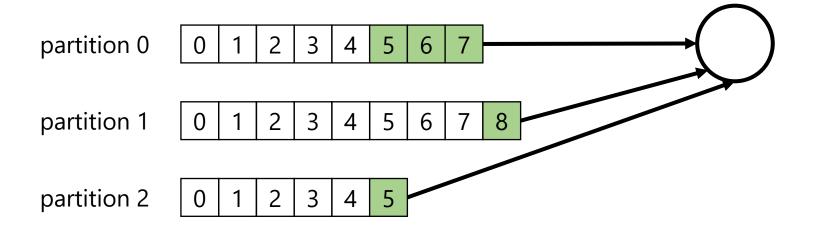


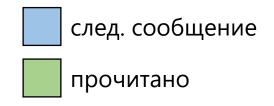


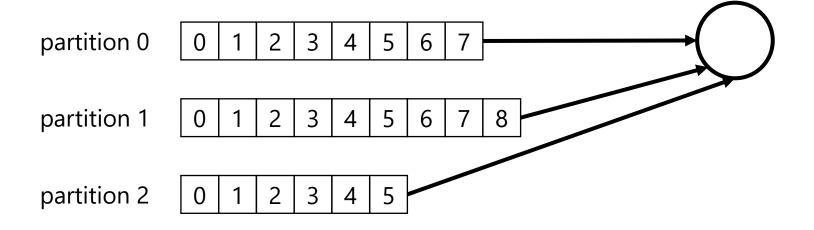


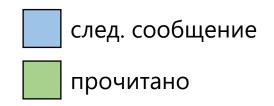












Commit offset

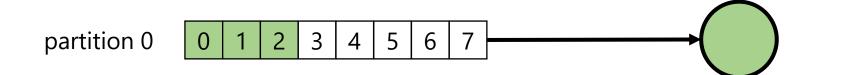
Commit offset

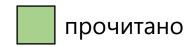
partition 0

0	1	2	3	4	5	6	7
---	---	---	---	---	---	---	---

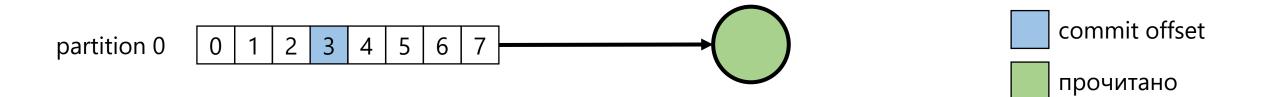


Commit offset

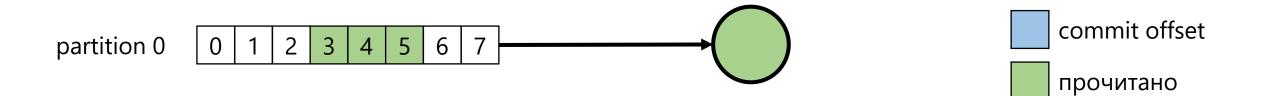




Commit offset



Commit offset

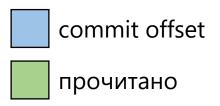


Commit offset

partition 0

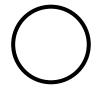


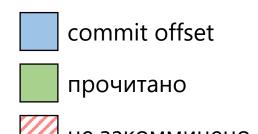




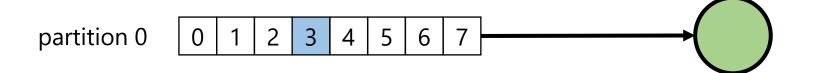
Commit offset

partition 0 0 1 2 3 4 5 6 7



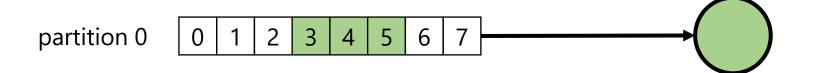


Commit offset





Commit offset





Гарантии обработки

- at least once
- mostly once

```
while (true) {
 /* */
  ConsumerRecords<UUID, Event> records =
        consumer.poll(timer.toDuration());
  consumer.commitAsync();
  process(records);
  /* */
```

```
while (true) {
  /* */
  ConsumerRecords<UUID, Event> records =
        consumer.poll(timer.toDuration());
  consumer.commitAsync();
  process(records);
                              mostly once
  /* */
                              Commit до обработки
```

```
while (true) {
 /* */
  ConsumerRecords<UUID, Event> records =
        consumer.poll(timer.toDuration());
  process(records);
  consumer.commitAsync();
  /* */
```

```
while (true) {
  /* */
  ConsumerRecords<UUID, Event> records =
        consumer.poll(timer.toDuration());
                              at least once
  process(records);
                              Commit после обработки
  consumer.commitAsync();
```

```
while (true) {
 /* */
  ConsumerRecords<UUID, Event> records =
        consumer.poll(timer.toDuration());
  process(records);
  consumer.commitAsync();
  /* */
```

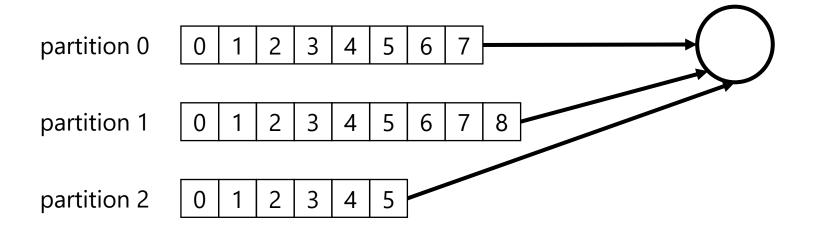
- 1 коммит на 1 сообщение
- 1 коммит на N сообщений

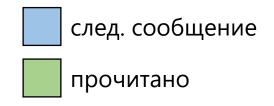
- 1 коммит на 1 сообщение
- 1 коммит на N сообщений ✓

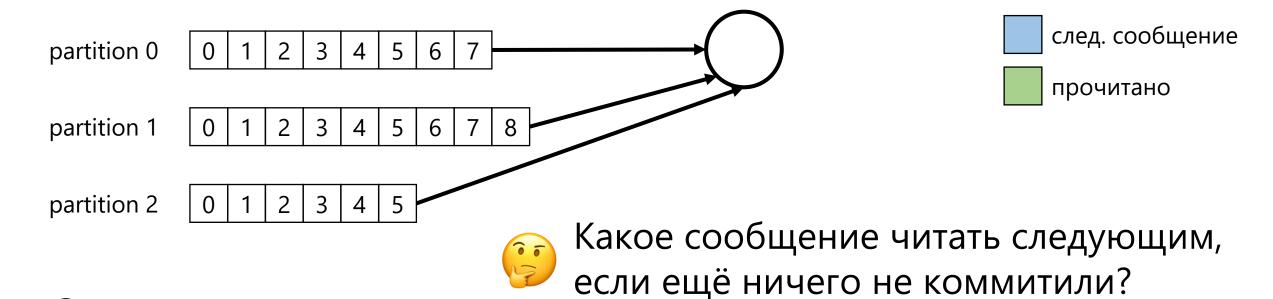
производительность

```
# Consumer properties
enable.auto.commit = true | false
auto.commit.interval.ms = 5000
```

```
# Consumer properties
enable.auto.commit = true | false
auto.commit.interval.ms = 5000
```









```
# Consumer properties
auto.offset.reset =
   earliest |
   latest |
   none
```

```
# Consumer properties
auto.offset.reset =
    earliest |
    latest |
    none
```

```
# Consumer properties
auto.offset.reset =
   earliest |
   latest |
   none
```

```
# Consumer properties
auto.offset.reset =
  earliest
  latest
  none
```



Значение по умолчанию

```
# Consumer properties
auto.offset.reset =
   earliest |
   latest |
   none
```

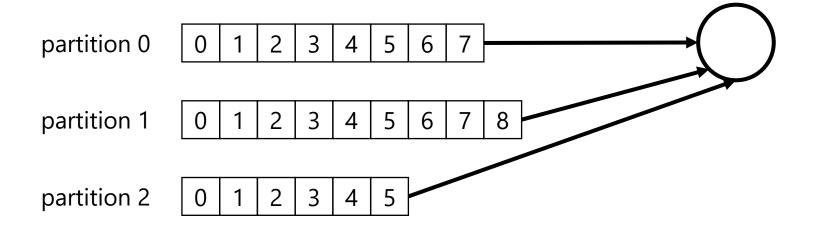
```
# Consumer properties
auto.offset.reset =
  earliest |
 latest
  none
```



Если нет сохранённого Commit Offset
— будет exception

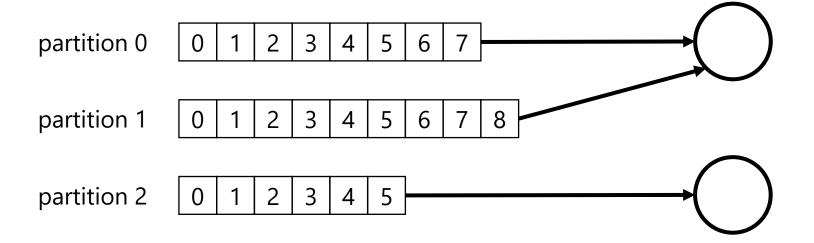
Consumer Group

Consumer Group

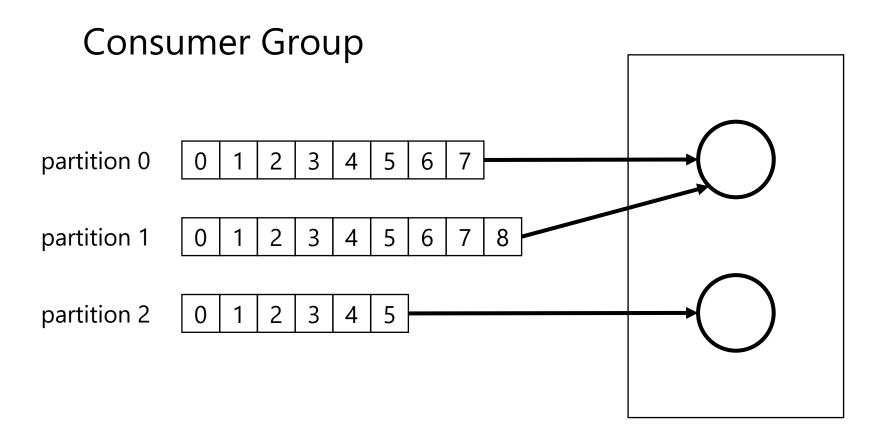


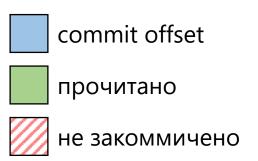


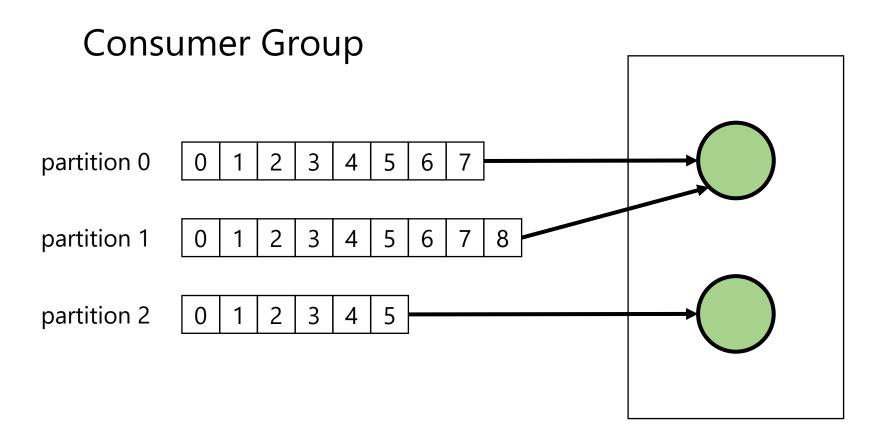
Consumer Group

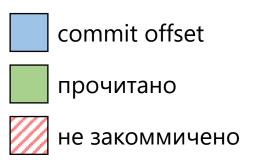


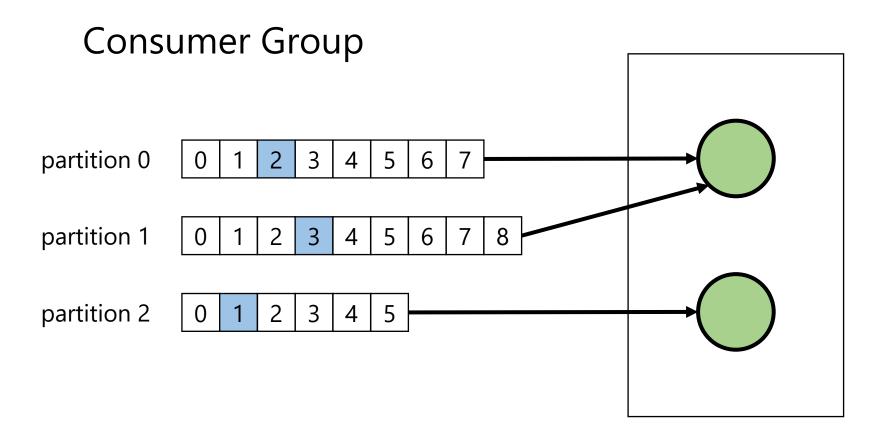


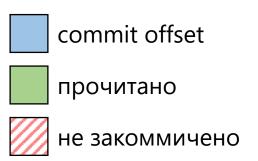


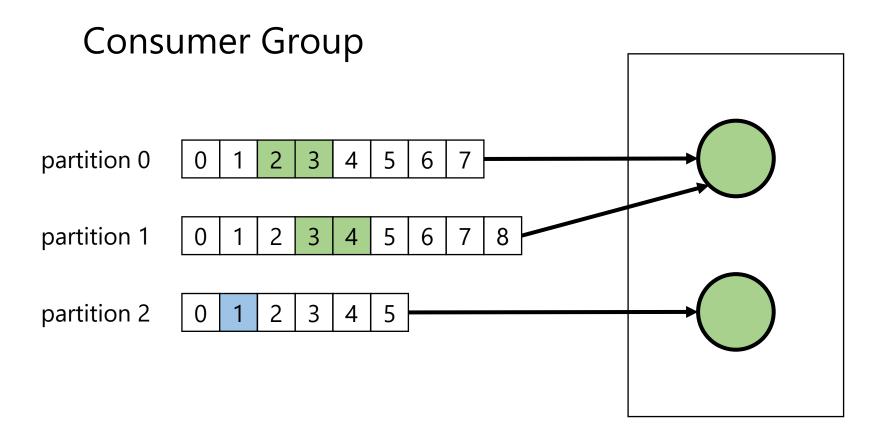


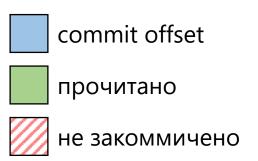


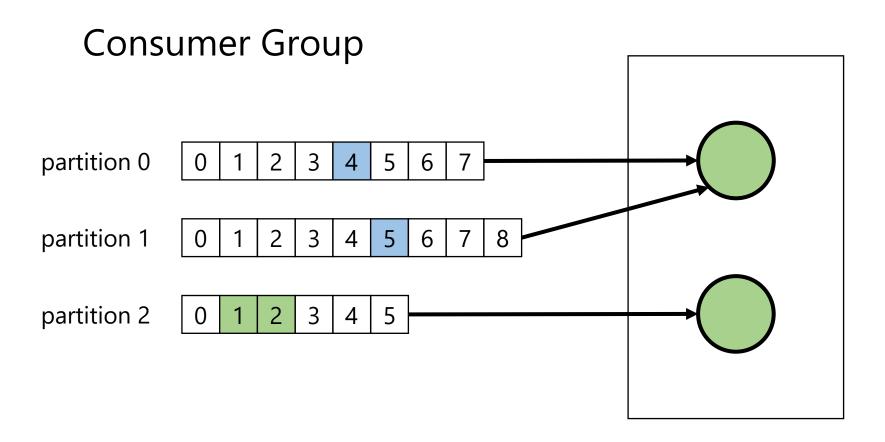


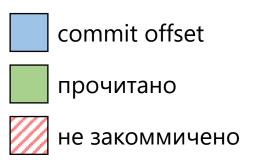


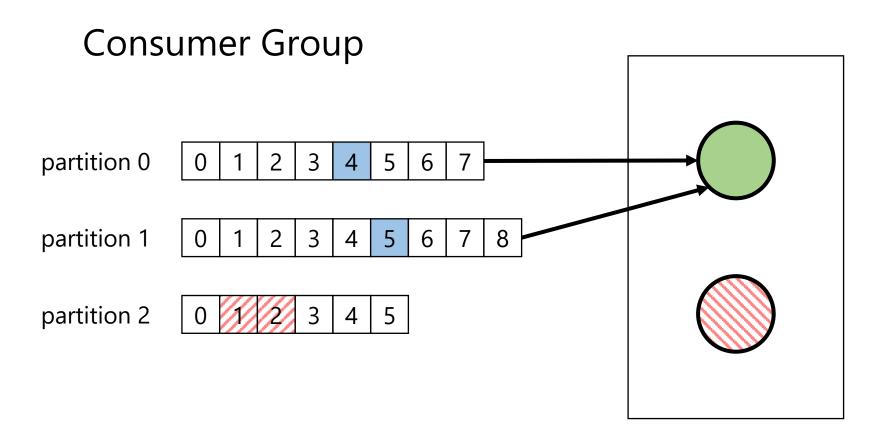


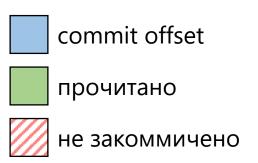


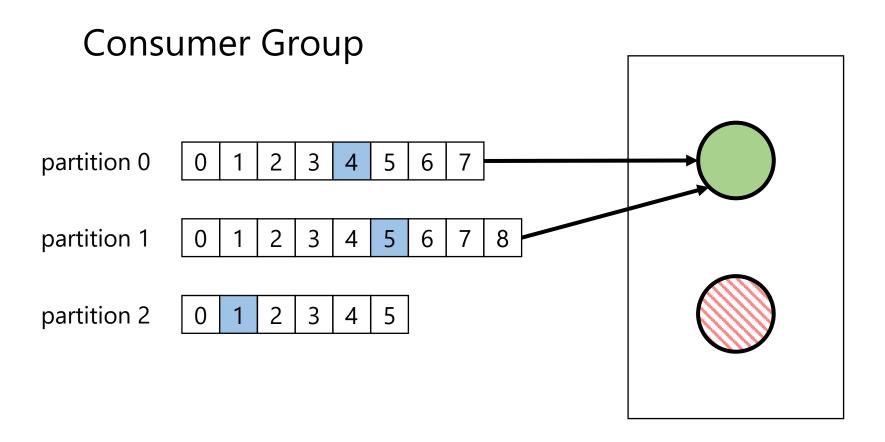


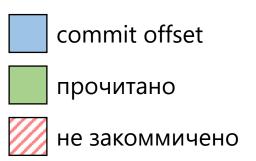


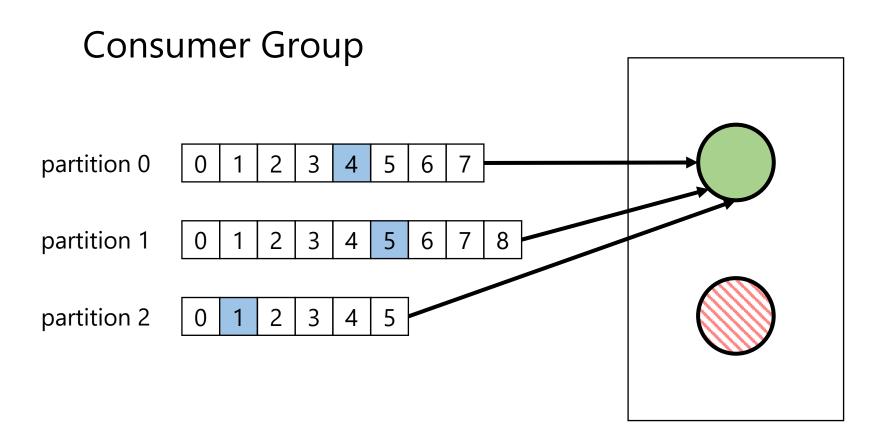


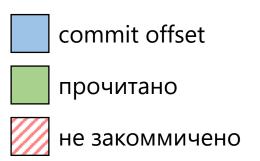


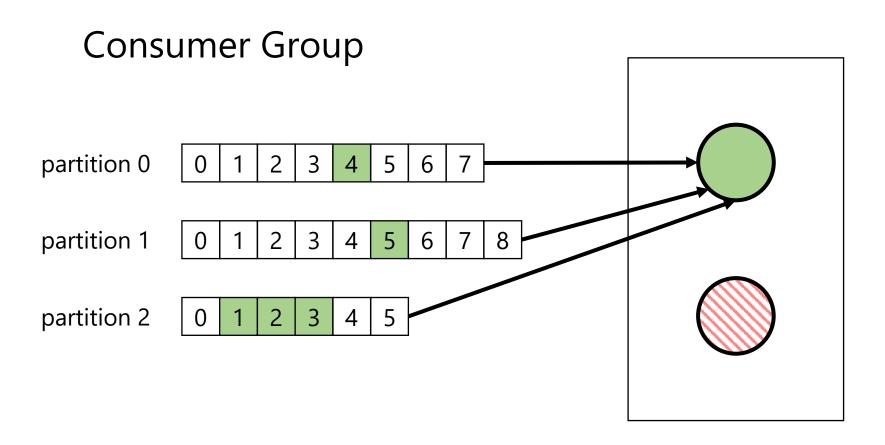


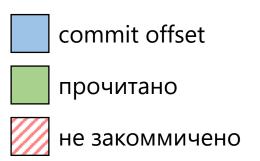


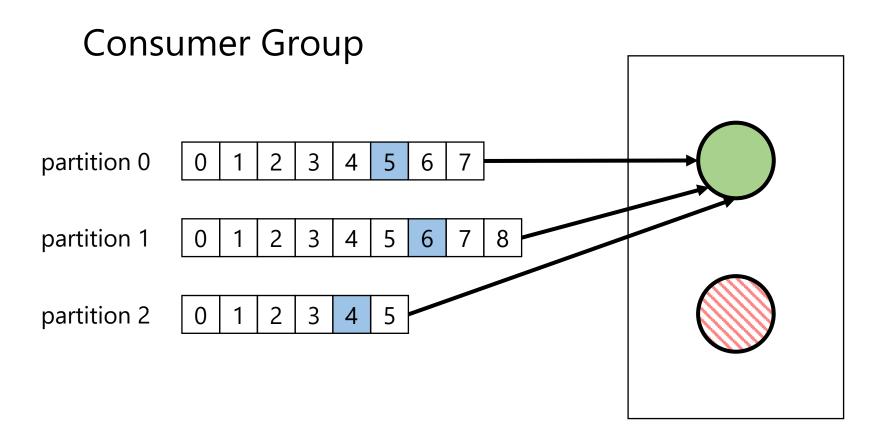


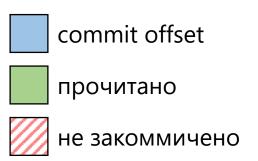


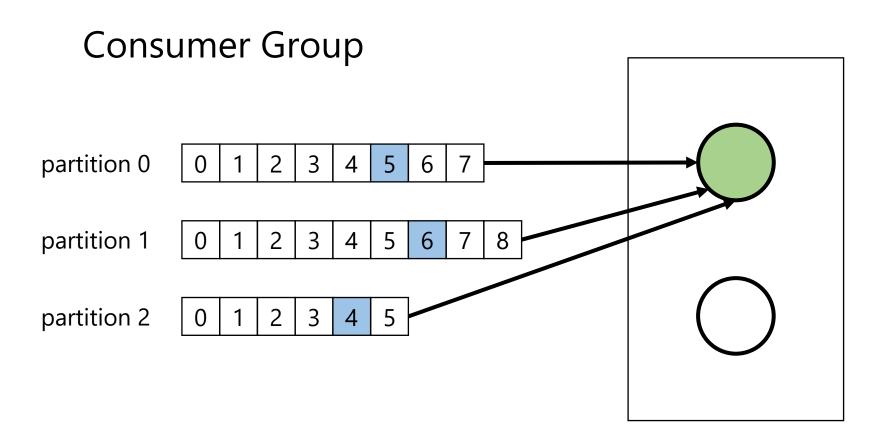


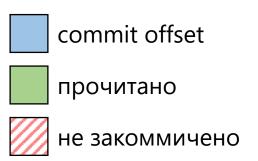


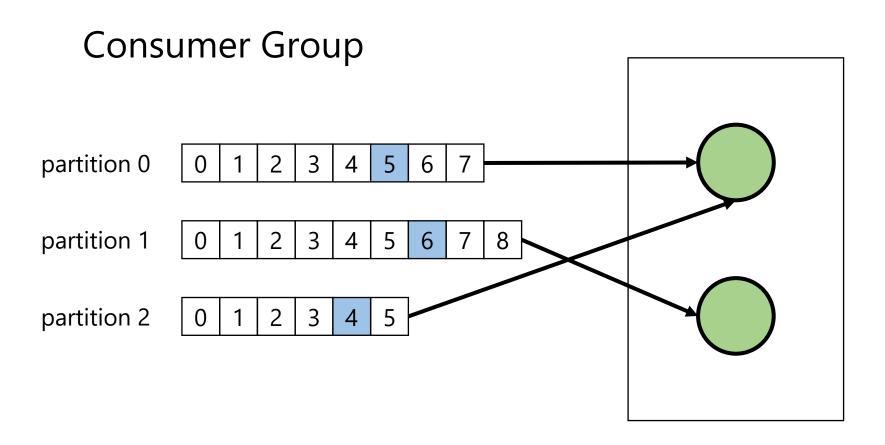


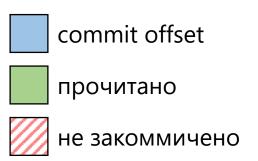




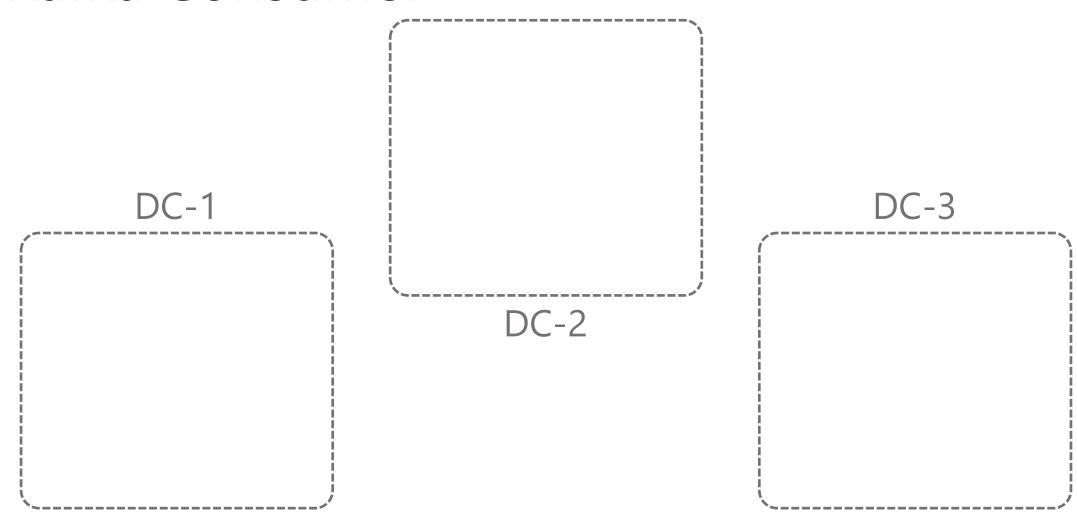


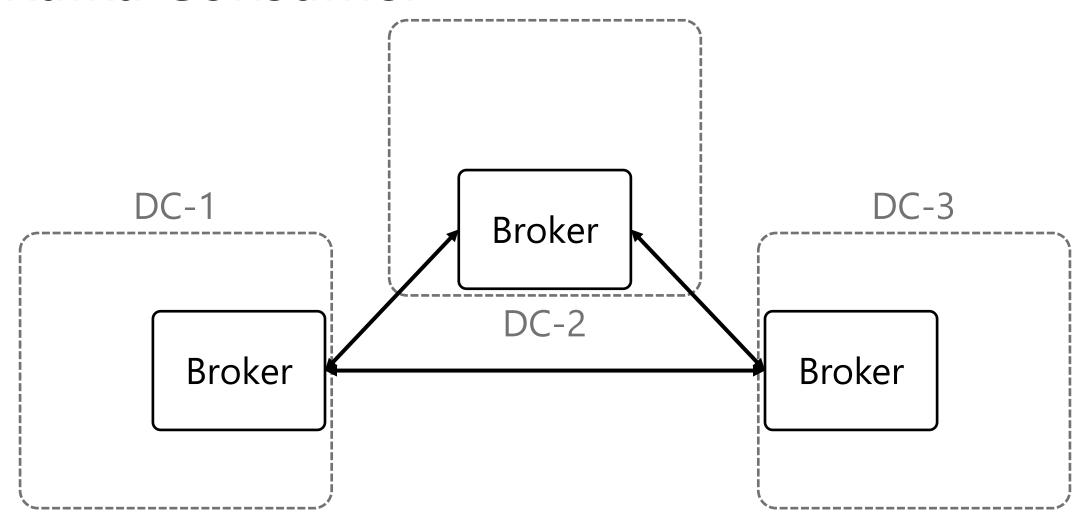


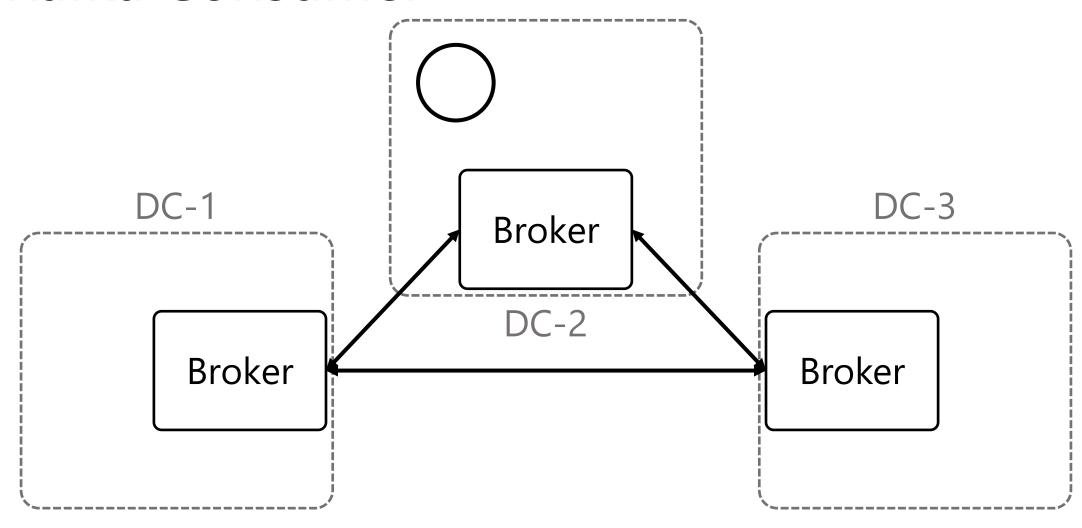


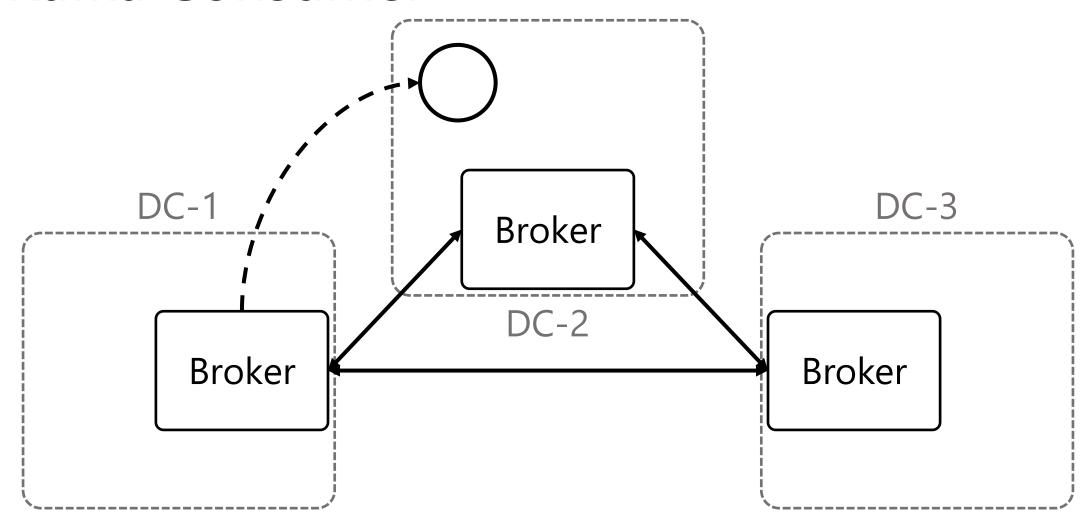


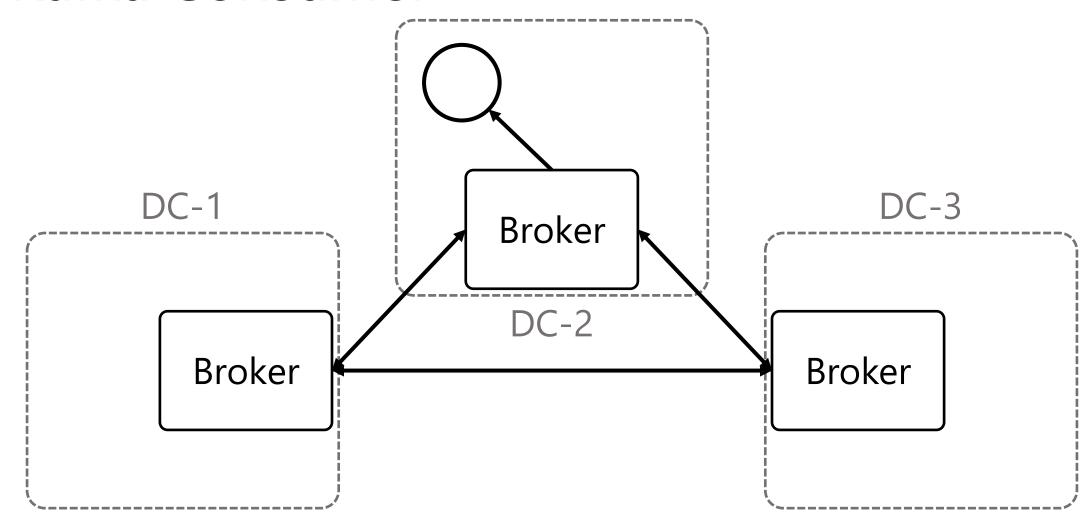
```
# Consumer properties
group.id =
   consumer-group-name
```

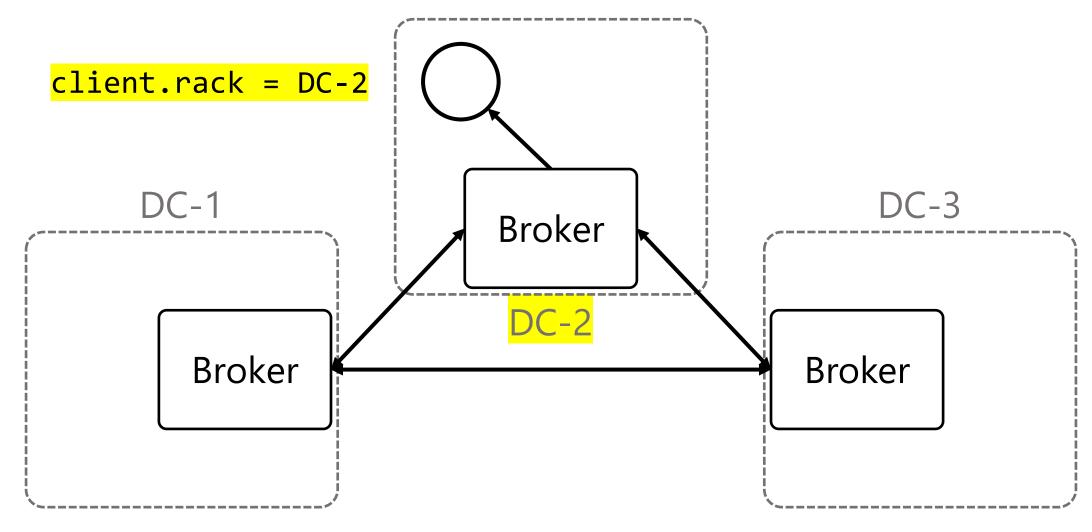












Выводы

- "Smart" Consumer
- Consumer поллит Кафку
- Consumer отвечает за гарантию обработки
- Автоматический фейловер в Consumer-группе
- Независимая обработка разными Consumer-группами

— Персистентность данных

- Персистентность данных
- Высокая производительность

- Персистентность данных
- Высокая производительность
- Независимость пайплайнов обработки

- Персистентность данных
- Высокая производительность
- Независимость пайплайнов обработки
- Возможность «проиграть» историю заново

- Персистентность данных
- Высокая производительность
- Независимость пайплайнов обработки
- Возможность «проиграть» историю заново
- Гибкость в использовании (благодаря простоте)

- Персистентность данных
- Высокая производительность
- Независимость пайплайнов обработки
- Возможность «проиграть» историю заново
- Гибкость в использовании (благодаря простоте)

— λ -архитектура и **K**-архитектура

- λ -архитектура и **K**-архитектура
- Стриминг данных

- λ -архитектура и K-архитектура
- Стриминг БОЛЬШИХ данных

- -- λ -архитектура и **K**-архитектура
- Стриминг БОЛЬШИХ данных
- Много клиентов (Producer и Consumer)

- -- λ -архитектура и **K**-архитектура
- Стриминг БОЛЬШИХ данных
- Много клиентов (Producer и Consumer)
- Требуется кратное масштабирование

- -- λ -архитектура и **K**-архитектура
- Стриминг БОЛЬШИХ данных
- Много клиентов (Producer и Consumer)
- Требуется кратное масштабирование
- Велосипедостроение

Чего нет в Kafka из коробки

Чего нет в Kafka из коробки



____ Каfkа — это не брокер сообщений!

Чего нет в Kafka из коробки

- Отложенные сообщения
- DLQ
- AMQP / MQTT
- TTL на сообщение
- Очереди с приоритетами

Q/A

Другие доклады и материалы: https://tg.me/chnl_GregoryKoshelev



Какие есть альтернативы?

- RabbitMQ Streams https://www.rabbitmq.com/streams.html
- Apache Pulsar https://pulsar.apache.org
- Apache RocketMQ https://rocketmq.apache.org